003 AgentForge

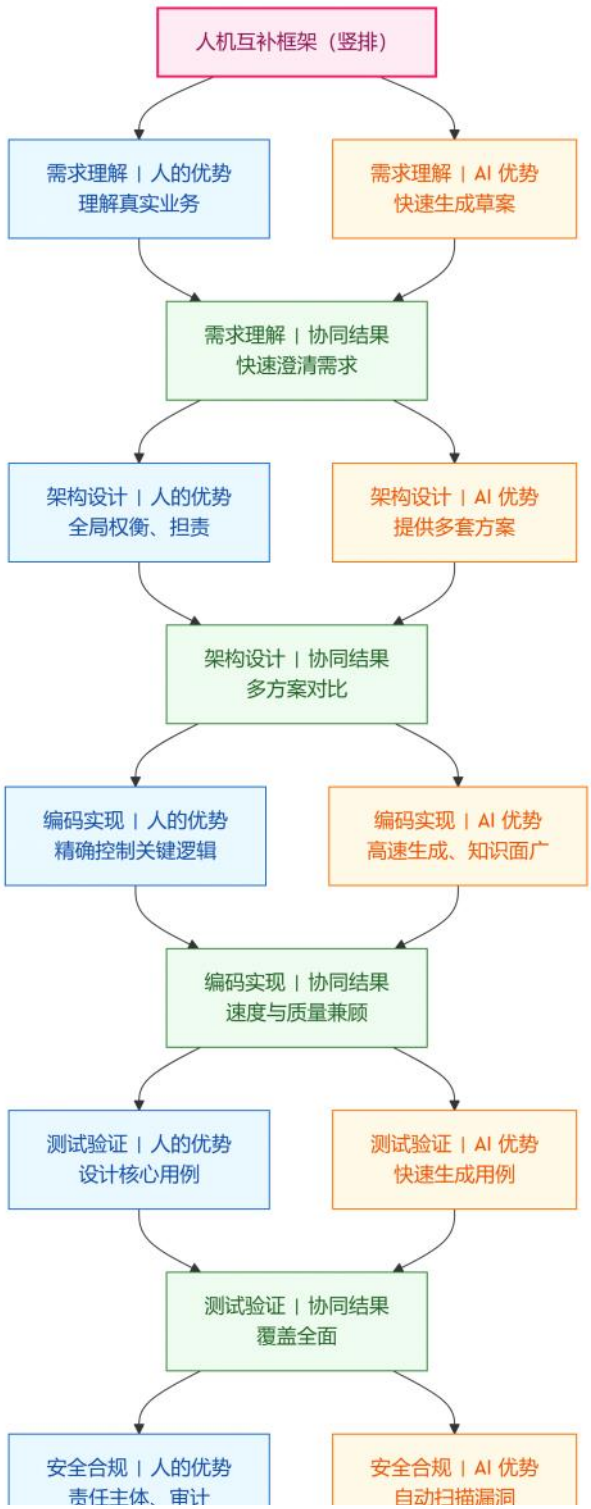
2026年9月2日 23:33

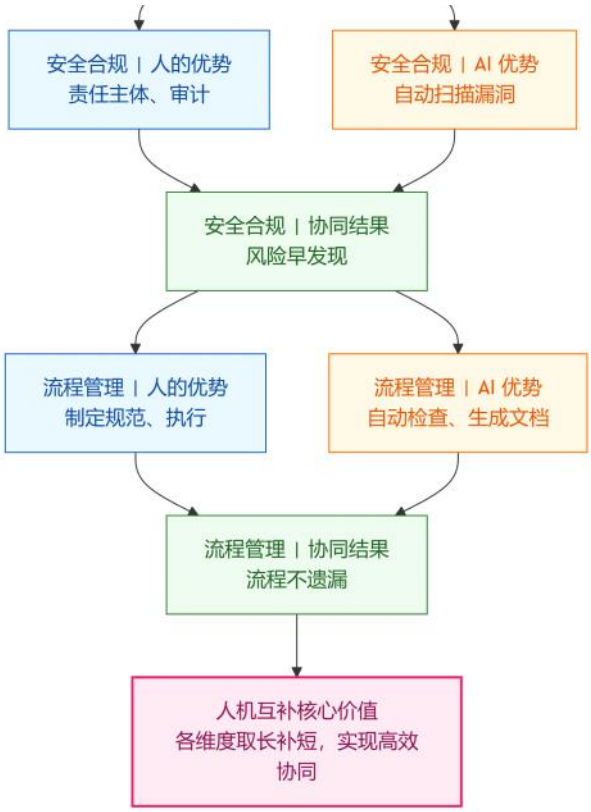
一. 目标

开发一个 Coder 类 AI Agent harness (AgentForge) ——AgentForge
让模型「看懂代码、修改代码、执行代码」的工作台。

1、理解AI harness原理（开发出一个可用的原型系统）；
2、人与AI协同的一次软件工程实践；
3、认清AI的能力边界（更有效地协同）
发现问题（缺陷）——制定应对策略
重复犯错——修正策略

二. 人与 AI 优缺点





三. 初识AI 缺陷

类别	核心表现	成因摘要
A 认知与知识缺陷	版本混淆、幻觉 API、领域知识偏差	静态训练数据、缺乏运行时验证
B 注意力与上下文缺陷	局部聚焦、约束丢失、多文件不一致	信息召回困难、上下文窗口限制
C 概率与一致性缺陷	输出随机偏移、过度自信、修改引入非预期变更	采样随机性、无置信度校准
D 记忆与状态缺陷	遗忘早期约束、重复犯错、忽略历史修改	无状态模型、上下文挤压
E 目标与行为偏差	盲目实现、垃圾代码、忽视约束、缺乏优化	优化目标非工程最优
F 对齐与欺骗性缺陷	擅自简化、测试作弊、注释与实现不符、违背约束	迎合倾向、捷径生成
G 责任与自我评估缺陷	无法自纠、混淆可编译与正确、不主动识别风险	无自我纠错回路、无执行环境

四. 渐进式协作层级与工具辅助

层级	名称	典型做法	工具辅助
L0	**简单提问**	直接问 AI，无约束	无
L1	**结构化提示词**	明确角色、任务、约束	格式工具（clang-format）
L2	**测试驱动生成**	先写测试，AI 实现	测试框架、ASan
L3	**契约式流程**	接口契约、代码规范、检查清单	静态分析、自定义脚本
L4	**规范化流程协作**	CI/CD、人工审批、审计	全套自动化流水线
L5	**Agent 辅助自动化**	AI 代理执行多步任务，人监督	Agent 自身受监控

五. 模块划分

